



Implementación de una red neuronal informada por la física para la obtención de perfiles de densidad y temperatura para un plasma que presenta un transporte clásico

Aaron Sanabria Martínez^{*} and Ricardo Solano Piedra^{**}

Escuela de Física, Universidad de Costa Rica. Sede Rodrigo Facio

Escuela de Física, Instituto Tecnológico de Costa Rica. Campus Cartago

(Dated: 3 de junio de 2026)

1. Introducción

El *deep learning* se ha integrado en la física por su capacidad para representar funciones complejas y aprender estructuras de relaciones matemáticas [1]. Dentro de estas, las redes neuronales (NNs) destacan por su capacidad para aproximar funciones, lo que las hace una opción para la resolución de sistemas diferenciales [2]. Las redes neuronales informadas por la física (PINNs) permiten tratar sistemas complejos de ecuaciones diferenciales usando restricciones físicas para obtener soluciones. Herramientas como la autodiferenciación permiten introducir las ecuaciones diferenciales (EDs) y sus condiciones de frontera como funciones de penalización que restringen el espacio de soluciones y explotan la capacidad de aproximación de las NNs [3, 4].

En el campo de plasmas se presenta no linealidad y acoplamiento en las ecuaciones que lo rigen. La dinámica de los plasmas está influenciada por interacciones electromagnéticas [5]. Estos sistemas son complejos debido a su comportamiento colectivo y una dinámica con múltiples regímenes de colisión que llevan al transporte de partículas [6]. La descripción de fluidos del plasma da un sistema cerrado de ecuaciones diferenciales parciales (PDEs) que puede ser modelado con una teoría de transporte clásico [7]. Pese a que estos sistemas pueden ser reducidos a uno de ecuaciones diferenciales ordinarias (ODEs) con modelos 1D, siguen siendo complejos de tratar [8, 9].

Los coeficientes y los términos fuentes en los sistemas de EDs que aparecen en los modelos de transporte colisional no son constantes, además de no lineales, por lo que el uso de PINNs es un buen método por su capacidad

de integrar y representar la no linealidad [10]. Por ejemplo, se han implementado PINNs para la resolución de ecuaciones unidimensionales del transporte de plasma a bajas temperaturas [10, 11]. Esquemas de PINNs aplicados en el transporte en Tokamaks han sido comparados con métodos tradicionales de diferencias finitas en la resolución de PDEs con beneficios como reducción en el tiempo de convergencia [12]. En el transporte turbulento para encontrar campos consistentes con las ecuaciones del fluido doble de Braginskii [13]. Sin embargo, no se ha reportado la implementación de una PINN aplicada al transporte perpendicular en geometría cilíndrica bajo el modelo de Braginskii reducido a ODEs con coeficientes dependientes de los perfiles.

No se ha reportado el uso de PINNs para el caso del transporte perpendicular para una geometría cilíndrica en la solución de las ecuaciones de fluido de Braginskii como un problema de ODEs con coeficientes dependientes de los perfiles. Las PINNs integran la no linealidad y la física al problema directamente en las funciones de pérdida usando la autodiferenciación (AD) sin uso de grillas.

2. Pregunta de investigación

La pregunta que se plantea contestar es: ¿puede una PINN, basada únicamente en restricciones físicas, reproducir perfiles radiales de densidad y temperatura en un plasma magnetizado bajo transporte clásico con un nivel de precisión comparable a datos experimentales del dispositivo de fusión Rijnhuizen Tokamak Project (RTP)?

^{*}Electronic address: aaron.sanabria@ucr.ac.cr

^{**}Electronic address: risolano@itcr.ac.cr

3. Objetivo general

Implementar una Red Neuronal Informada por la Física (PINN) para la determinación de los perfiles radiales de densidad electrónica y temperatura electrónica en un plasma magnetizado cilíndrico que exhibe transporte clásico perpendicular al campo magnético.

Objetivos específicos

1. Formular las ecuaciones que relacionan la densidad electrónica y temperatura electrónica a partir de la teoría de transporte clásico perpendicular al campo magnético para la base del diseño de la PINN.
2. Diseñar la arquitectura de la PINN de acuerdo al modelo teórico mediante la definición de las capas, las funciones de activación y los hiperparámetros esenciales de la red.
3. Evaluar cuantitativamente la precisión de la PINN mediante la comparación con perfiles experimentales del RTP utilizando métricas como error cuadrático medio (MSE) y análisis de consistencia física.

4. Marco teórico

4.1. Redes neuronales informadas por la física: fundamentos

Las **neuronas** artificiales son funciones matemáticas y son la estructura básica de las NNs. Las neuronas se conectan entre sí usando capas que toman como argumentos vectores de salida de las capas previas. Los perceptrones multicapa (MLP) son una NN completamente conectada donde la información fluye únicamente de la capa de entrada a la capa de salida, sin ciclos ni retroalimentación, i.e., $\mathcal{F}: X \rightarrow Y$ con $\mathcal{F} = f^{(L)} \circ f^{(L-1)} \circ \dots \circ f^{(1)}$ con X es el espacio de entradas y Y el espacio de salidas. Cada capa aplica una transformación afín seguida de una activación no lineal por la función $\sigma(\cdot)$ que debe ser diferenciable.

$$f^{(k)}(\mathbf{x}_{k-1}) = \sigma(\mathbf{W}^{(k)}\mathbf{x}_{k-1} + \mathbf{b}^{(k)}) \quad (1)$$

donde $\mathbf{W}^{(k)}$ es una matriz de pesos y $\mathbf{b}^{(k)}$ el sesgo, son parámetros de la NN que se ajustan durante el entrenamiento. Una función general continua puede ser aproximada con precisión arbitraria usando MLPs [14, 15].

En la Figura 1 se muestra el esquema general de lo que es un MLP.

Las entradas, salidas y transformaciones en las NNs se guardan en tensores que almacenan los parámetros e hiperparámetros de la MLP, así como el grafo de cómputo




Figura 1: MLP con dos capas ocultas. Adaptado de [16] bajo licencia CC BY-NC-SA 4.0.

de las operaciones sobre ellos y sus derivadas locales. Esto da paso al método AD que parte del principio de que toda operación computacional puede ser descompuesta en operaciones elementales con derivadas conocidas. La función de activación debe ser diferenciable en los puntos donde se aplica AD para evitar problemas con las derivadas.

4.1.1. Funciones de pérdida

Las funciones de pérdida $\mathcal{L}(\{x_i\}, \theta)$ cuantifican cuánto se apegan los modelos a las restricciones que se les imponen en determinados puntos $\{x_i\} \in X$ conocidos como puntos de colocación. Durante el entrenamiento se minimiza $\mathcal{L}(\theta)$ al variar los parámetros internos del modelo $\theta := \{\mathbf{W}^{(k)}, \mathbf{b}^{(k)}\}$. Las funciones $\mathcal{L}(\theta)$ pueden contener múltiples términos correspondientes a diferentes condiciones sobre el modelo; si se imponen sobre las EDs que rigen un sistema físico y sus condiciones de frontera, surge el concepto de PINN [3].

Las NNs requieren tanto de los parámetros θ como de los hiperparámetros de la red Θ que contienen el número de capas $L+1$, el ancho de la red, la función de activación que se usa σ , etc. Una arquitectura de NN robusta requiere de una fase de entrenamiento donde se optimizan los valores de θ dado un conjunto de Θ fijos [16].

4.1.2. Optimizadores

Los algoritmos de optimización modernos parten del algoritmo de descenso por gradiente (GD), donde se usa la dirección opuesta al gradiente de $\mathcal{L}(\theta)$ y un hiperparámetro llamado tasa de aprendizaje η que es el tamaño del paso usado. Es la base de algoritmos más eficientes.

Los algoritmos basados en GD pueden desvanecerse o explotar. Esto se previene controlando la varianza de las

señales que se pasan a la NN al inicializar los parámetros con valores aleatorios de una distribución uniforme o normal. El inicializador Xavier trata las derivadas de la función de pérdida como variables aleatorias [17].

El estimador adaptativo de momentos (Adam) está basado en gradientes estocásticos de primer orden donde las η son adaptativas. Se introducen momentos que guardan el historial del gradiente $\nabla_{\theta}\mathcal{L}$. El método es robusto para tratar problemas dispersos y con ruido [18].

El algoritmo de memoria limitada Broyden-Fletcher-Goldfarb-Shanno (L-BFGS) es un método de memoria cuasi-newtoniano de segundo orden que estima la matriz hessiana de $\mathcal{L}(\theta)$ respecto a los parámetros sin calcular todos los elementos de la matriz, cerca de un mínimo la convergencia es más rápida que en métodos de primer orden.

4.2. Plasmas magnetizados y teoría clásica de transporte perpendicular

Un plasma es un gas ionizado que presenta comportamiento colectivo y cuasi-neutralidad. La dinámica del plasma está gobernada por interacciones electromagnéticas de largo alcance tanto por campos que se generan a nivel interno como por campos exteriores. La teoría de transporte colisional estudia el transporte de partículas, momento y energía en un régimen dominado por colisiones. Cuando partículas, momento y energía se transportan en dirección perpendicular a un campo magnético establecido en el plasma, se alude al concepto de transporte perpendicular. La teoría de transporte clásico estudia la contribución de las colisiones al transporte perpendicular en un plasma magnetizado [5].

4.2.1. Ecuación cinética de Boltzmann

Una descripción estadística asume que hay suficientes partículas en el sistema para tener una descripción macroscópica con temperatura y densidad bien definidas. Se trabaja en un espacio de fase 6-dimensional $(\mathbf{x}, \mathbf{v})$. Primero se introduce el operador d/dt como

$$\frac{d}{dt} \equiv \partial_t + \mathbf{v} \cdot \nabla + \frac{Z_{\alpha}e}{m_{\alpha}}(\mathbf{E} + \mathbf{v} \times \mathbf{B}) \cdot \nabla_{\mathbf{v}} \quad (2)$$

este operador toma en cuenta la evolución temporal local, la advección espacial y la interacción electromagnética con campos externos. Las especies en un plasma pueden ser especificadas por una función de distribución $f_{\alpha}(\mathbf{x}, \mathbf{v}, t)$ mediante la siguiente ecuación:

$$\left[\frac{d}{dt} - C_{\alpha,\beta} \right] f_{\alpha} = 0 \quad (3)$$

en este caso $C_{\alpha,\beta}$ es un operador de colisiones binarias entre especies α y β que describe colisiones que se dan en el medio.

Al integrar la ecuación (3) respecto al espacio de velocidades con pesos g_k correctos, se puede obtener la descripción de fluidos en el plasma al tomar los momentos $k = 0$ y $k = 2$. La ecuación (4) describe el flujo de partículas de plasma a partir de g_0

$$\partial_t n_{\alpha} + \nabla \cdot \mathbf{\Gamma}_{\alpha} = S_{\alpha} \quad (4)$$

con n_{α} y $\mathbf{u}_{\alpha}$ la densidad y velocidad promedio del plasma respectivamente, $\mathbf{\Gamma}_{\alpha} = n_{\alpha}\mathbf{u}_{\alpha}$ el flujo de partículas y S_{α} un término de fuentes y sumideros. Por otro lado, la ecuación (5), que describe el flujo de energía en el plasma, se obtiene a partir de g_2

$$\partial_t W_{\alpha} + \nabla \cdot \mathbf{Q}_{\alpha} = P_{\alpha} \quad (5)$$

con W_{α} la densidad de energía del sistema, $\mathbf{Q}_{\alpha}$ el flujo de energía y P_{α} términos de potencia y disipación de energía [5, 7].

4.2.2. Colisiones y procesos atómicos en el plasma

Los términos de fuente y sumideros en las ecuaciones (4) y (5) se relacionan con procesos atómicos y pueden modelarse como [6]

$$N_{\text{proceso}} = n_{\alpha}n_{\beta}\langle\sigma v\rangle_{\text{proceso}} \quad (6)$$

$$S_{\text{proceso}} = E_{\text{proceso}}n_{\alpha}n_{\beta}\langle\sigma v\rangle_{\text{proceso}} \quad (7)$$

donde σ es la sección efectiva de la colisión. Los términos de fuente y sumidero de partículas así como la energía dependen de $\langle\sigma v\rangle$, la tasa a la cual ocurren las colisiones que dan lugar al proceso atómico.

4.2.3. Procesos de calentamiento en el plasma

En los procesos de calentamiento se debe considerar el esfuerzo viscoso en el plasma $\mathbf{\Pi}_{\alpha}$ y la presión mecánica p_{α} . El flujo de calor $\mathbf{Q}_{\alpha}$ puede dividirse en diferentes contribuciones tal que

$$\mathbf{Q}_{\alpha} = \mathbf{q}_{\alpha} + \frac{3}{2}T_{\alpha}\mathbf{\Gamma}_{\alpha} + p_{\alpha}\mathbf{u}_{\alpha} + \mathbf{\Pi}_{\alpha} \cdot \mathbf{u}_{\alpha} + \frac{1}{2}m_{\alpha}u_{\alpha}^2\mathbf{\Gamma}_{\alpha} \quad (8)$$

Las diferentes contribuciones de flujos corresponden en orden a: calentamiento conductivo, convectivo, la entalpía o trabajo que hace la presión mecánica sobre el plasma, el transporte viscoso de energía y la convección de energía cinética [5]. Bajo ciertos supuestos es posible despreocupar algunas de estas contribuciones.

4.2.4. Parámetros característicos del plasma

El radio de Debye $\lambda_D = \sqrt{\epsilon_0 T / n_e e^2}$ es una distancia en la que el potencial de Coulomb se ve apantallado por el comportamiento colectivo de las partículas. Con λ_D y el parámetro de impacto mínimo $b_{\min}$ se define la cantidad $\Lambda \equiv \lambda_D / b_{\min} = 4\pi\epsilon^{3/2} e^{-3} T_e^{3/2} n_e^{-1/2}$ [5, 6]. Se define el tiempo de relajación $\tau_{\alpha,\beta}$ que es el periodo típico entre colisiones electrónicas

$$\langle \nu_{ie} \rangle = \frac{4}{3} \sqrt{\frac{2\pi}{m}} \left(\frac{Ze^2}{4\pi\epsilon_0} \right)^2 \ln \Lambda \frac{n}{T^{3/2}} \quad (9)$$

En el plasma se da difusión de partículas y energía. Para un plasma cilíndrico con $\mathbf{B}$ uniforme y presión constante, los flujos tienen la forma [5]

$$\mathbf{\Gamma}_e \approx -D_{\perp}(n_e, T_e) \partial_r n_e \quad \text{con} \quad D_{\perp} = \frac{T_e}{m_e \omega_e^2 \tau_{ei}} \quad (10)$$

$$\mathbf{q}_e \approx -\chi_{\perp}(n_e, T_e) \partial_r T_e \quad \text{con} \quad \chi_{\perp} = 4.66 \frac{n_e T_e}{m_e \omega_e^2 \tau_{ei}} \quad (11)$$

con ω_e es la frecuencia ciclotrónica del electrón.

5. Metodología

Para la derivación teórica de las ecuaciones que determinan los perfiles de densidad n y temperatura T electrónicos, se parte de las ecuaciones (4), (5) y de los siguientes supuestos:

- Cuasi-neutralidad: $n_i \approx n_e$.
- Plasma débilmente ionizado: $n_e \ll n_0$.
- Plasma frío: $T_i \ll T_e$.
- Caso estacionario con difusión ambipolar $\mathbf{\Gamma}_i \approx \mathbf{\Gamma}_e$.
- Geometría cilíndrica del plasma con transporte en la dirección radial: $T_e = T_e(r)$, $n_e = n_e(r)$.
- La temperatura y densidad son continuas y diferenciables a lo largo del plasma.
- Campo magnético $\mathbf{B}$ uniforme en la dirección $\hat{z}$ y campo eléctrico externo $\mathbf{E} = \mathbf{0}$.
- La densidad de neutros es aproximadamente uniforme en el espacio $n_0 \approx \text{constant}$.
- La deposición de potencia en el plasma sigue un perfil gaussiano $P(r) = P_{\text{ext}} \mathcal{N}(r; \mu, \sigma) / N$ normalizado por N .
- El flujo de energía está dominado por convección y conducción: $\mathbf{Q} \approx \mathbf{q} + \frac{3}{2} T \mathbf{\Gamma}$

A partir de ahora se omitirá la etiqueta α que caracteriza la especie. Se llegará a un sistema de ODEs donde los perfiles serán normalizados respecto a $n_{\max}$ y $T_{\max}$ asumiendo que los perfiles alcanzan su máximo en el centro

del plasma. El sistema resultante es de la forma

$$\begin{cases} F(r, \partial_r \hat{n}, \partial_r \hat{T}, \partial_r^2 \hat{n}, \partial_r^2 \hat{T}, \Psi) = 0, & r \in [0, R] \\ G(r, \partial_r \hat{n}, \partial_r \hat{T}, \partial_r^2 \hat{n}, \partial_r^2 \hat{T}, \Psi) = 0, \\ \hat{n}(0) - 1 = 0, & \partial_r \hat{n}|_{r=0} = 0, \\ \hat{T}(0) - 1 = 0, & \partial_r \hat{T}|_{r=0} = 0, \\ \partial_r \hat{n}|_{r=R} + \hat{n}(R) / \lambda_n = 0 \\ \partial_r \hat{T}|_{r=R} + \hat{T}(R) / \lambda_T = 0 \end{cases} \quad (12)$$

donde λ_n y λ_T son las escalas características de decaimiento en $r = R$ y con $\Psi = \{R, B, n_0, P_{\text{ext}}, \lambda_n, \lambda_T, \mu, \sigma\}$ el conjunto de parámetros libres del sistema. R , el radio del plasma cilíndrico. Las condiciones en $r = 0$ corresponden a la simetría axial del sistema. El orden dos es de esperar por las ecuaciones (10) y (11).

5.1. Implementación de la red

Se construirá una MLP inicializada con Xavier activada por una función tanh. Consistirá en una capa de entrada r , múltiples capas ocultas L y una capa de salida con dos neuronas $[\hat{n}(r; \theta), \hat{T}(r; \theta)]$ en Python usando PyTorch [19] para construir la PINN. Se entrenará con GPUs del clúster de la Universidad de Costa Rica. Las funciones de pérdida serán puramente físicas de la forma [3]:

$$\mathcal{L}(r; \theta) = \omega_{\mathcal{N}} \mathcal{L}_{\mathcal{N}}(r; \theta) + \omega_{bc} \mathcal{L}_{bc}(r; \theta) \quad (13)$$

con

$$\mathcal{L}_{\mathcal{N}}(r; \theta) = \frac{1}{N_{\mathcal{N}}} \sum_{i=1}^{N_{\mathcal{N}}} \|\mathcal{N}(r, \partial_r \hat{n}, \partial_r \hat{T}, \partial_r^2 \hat{n}, \partial_r^2 \hat{T}, \Psi)\|_2^2 \quad (14)$$

$$\mathcal{L}_{bc}(r; \theta) = \frac{1}{N_{bc}} \sum_{i=1}^{N_{bc}} \|f_{bc}(r_0)\|_2^2 \quad (15)$$

aquí N_i y ω_i son los puntos de colocación y pesos para las funciones de pérdida respectivamente que determinarán experimentalmente junto con L para mejorar la convergencia. $\mathcal{L}_{\mathcal{N}}$ corresponde a la contribución de la restricción impuesta por las ODEs $\mathcal{N} = (F, G)$ y sus condiciones de frontera $\mathcal{L}_{bc}$ por $f_{bc}(r_0) = 0$ evaluadas en los extremos $r_0 = 0$ y $r_0 = R$.

Para optimizar los parámetros PINN se usará el esquema de dos optimizadores. Una primera optimización con Adam seguida de un refinamiento usando L-BFGS.

Dentro de (12) aparecen términos de disipación de energía y partículas relacionadas con las tasas $\langle \sigma v \rangle$, estas dependen de la temperatura y se determinan numéricamente de la base de datos ADAS con la librería *Cherab v1.5* [20] para un gas de hidrógeno usado en los disparos elegidos del tokamak RTP.

5.1.1. Criterio de convergencia

Se utilizará como métrica principal el error cuadrático medio (MSE)

$$MSE = \frac{1}{n} \sum_{i=1}^m (y_i - \hat{y}_i)^2 \quad (16)$$

donde se compararán los perfiles medidos para RTP con los obtenidos de la PINN. A partir de una tolerancia en la pérdida, estabilidad del entrenamiento, comparación del perfil radial, error relativo y comportamiento físico (monotonía, regularidad) con los que se calibrarán los hiperparámetros de la red. Aún se está valorando si la calibración será manual o se usará algún método como la interferencia bayesiana.

5.2. Obtención de datos para comparar perfiles

A partir de $n(r)$ y $T(r)$ de la PINN se compararán con perfiles medidos para el dispositivo RTP en los disparos #96040237, #97052261 y #97053056. Se promediarán temporalmente para obtener perfiles estacionarios. Los datos serán obtenidos de la base de datos IMDB [21] usando MDSPlus [22].

6. Resultados y discusión

Partiendo de las ecuaciones de flujo de partículas y energía Eqs. (4) y (5), las fuentes y sumideros de partículas y disipación de potencia Eqs. (6) y (7) en el plasma, la difusión de partículas y energía Eqs. (10) y (11). Además de la aproximación del flujo de calor dado en la Eq. (8) se obtiene la siguiente ODE para la el flujo de partículas:

$$\frac{h}{r} \frac{d}{dr} \left(r \frac{n}{T^{1/2}} \frac{dn}{dr} \right) + N(n, T) = 0 \quad (17)$$

donde se tienen las fuentes y sumideros $N(n, T) = N_{ion}(n, T) - N_{rec}(n, T)$. Además se define la constante h como:

$$h \equiv \sqrt{\frac{e^4 l^2 m}{\pi^3 \epsilon_0^4 B^4}}. \quad (18)$$

Similarmente, se llega a una ODE para la ecuación de energía tal que:

$$\begin{aligned} \frac{h}{r} \frac{d}{dr} \left(r \frac{n^2}{T^{1/2}} \frac{dT}{dr} \right) + h \frac{n}{T^{1/2}} \frac{dn}{dr} \frac{dT}{dr} - TN(n, T) \\ + P(r) - S(n, T) - \frac{3e^2 B^2 h}{m_i} \frac{n^2}{T^{1/2}} = 0 \end{aligned} \quad (19)$$

con el proceso de disipación de potencia como $S = S_{ion} + S_{rec} + S_{rad}^0 + S_{rad}^i$, todos dependientes de n y T . Mientras que el la deposición de potencia se modela con el perfil gaussiano:

$$P(r) = \frac{P_{ext}}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{r - \langle r \rangle}{\sigma} \right)^2 \right] \quad (20)$$

A partir de estas ODEs y haciendo siguiente cambio de variables para normalizar el problema:

$$\rho = \frac{r}{R}, \quad \hat{n} = \frac{n - n_{min}}{\Delta_n}, \quad \hat{T} = \frac{T - T_{min}}{\Delta_T}, \quad (21)$$

con $\Delta_x = x_{max} - x_{min}$. Se procedió a adimensionar las ODEs y remover posibles denominadores que pudieran presentar valores singulares durante la solución con la PINN, de tal forma que se llega a una ODEs normalizadas numéricamente estables. Para la ODE del flujo de partículas:

$$\begin{aligned} \frac{n}{\Delta_n} \frac{T}{\Delta_T} \left[\rho \frac{d^2 \hat{n}}{d\rho^2} + \frac{d\hat{n}}{d\rho} \right] + \rho \frac{T}{\Delta_T} \left(\frac{d\hat{n}}{d\rho} \right)^2 - \frac{\rho}{2} \frac{n}{\Delta_n} \frac{d\hat{n}}{d\rho} \frac{d\hat{T}}{d\rho} \\ + \frac{R^2 \Delta_T^{1/2}}{h \Delta_n^2} \left(\frac{T}{\Delta_T} \right)^{3/2} \rho N(\hat{n}, \hat{T}) = 0 \end{aligned} \quad (22)$$

donde se usa $x/\Delta_x = \hat{x} + x_{min}/\Delta_x$. De forma similar se llega a la expresión para la ODE del flujo de energía:

$$\begin{aligned} \frac{47}{10} \left(\frac{n}{\Delta_n} \right)^2 \frac{T}{\Delta_T} \left(\rho \frac{d^2 \hat{T}}{d\rho^2} + \frac{d\hat{T}}{d\rho} \right) + \frac{52\rho}{5} \frac{n}{\Delta_n} \frac{T}{\Delta_T} \frac{d\hat{n}}{d\rho} \frac{d\hat{T}}{d\rho} \\ - \frac{47\rho}{20} \left(\frac{n}{\Delta_n} \frac{d\hat{n}}{d\rho} \right)^2 - \frac{3w_b}{\Delta_T} \frac{T}{\Delta_T} \left(\frac{n}{\Delta_n} \right)^2 \\ - \frac{R^2 \Delta_T^{1/2}}{h \Delta_n^2} \left(\frac{T}{\Delta_T} \right)^{3/2} \frac{\rho}{\Delta_T} \left\{ TN(\hat{n}, \hat{T}) + S(\hat{n}, \hat{T}) \right. \\ \left. - \frac{P_{ext}}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{R}{\sigma} \right)^2 (\rho - \hat{\mu})^2 \right] \right\} = 0 \end{aligned} \quad (23)$$

con $w_b \equiv e^2 R^2 B^2 / m_i$ y $\hat{\mu} = \langle \rho \rangle$. Los parámetros libres del modelo son $\{\hat{\mu}, \sigma\}$ para el modelado del perfil Gaussiano de deposición de potencia. Mientras que los parámetros $\{n_{min}, T_{min}, n_{max}, T_{max}, P_{ext}, B, R\}$ se pueden ajustar con los datos típicos del dispositivo que se está estudiando.

7. Uso de inteligencia artificial

Se usó la LLM Claude para búsqueda bibliográfica, revisión ortográfica y estructural del texto. Se usará para *debugging* de código.

Referencias

- [1] G. Carleo, I. Cirac, K. Cranmer, L. Daudet, M. Schuld, N. Tishby, L. Vogt-Maranto, and L. Zdeborová, *Rev. Mod. Phys.* **91**, 045002 (2019).
- [2] I. Lagaris, A. Likas, and D. Fotiadis, *IEEE Transactions on Neural Networks* **9**, 987 (1998).
- [3] M. Raissi, P. Perdikaris, and G. E. Karniadakis, *Journal of Computational Physics* **378**, 686 (2019).
- [4] A. G. Baydin, B. A. Pearlmutter, A. A. Radul, and J. M. Siskind, *Journal of Machine Learning Research* **18**, 1 (2018).
- [5] D. J. S. Per Helander, *Collisional Transport in Magnetized plasmas*, Cambridge Monographs on Plasma Physics (Cambridge University Press, 2005).
- [6] G. R.J. and R. P.H., *Introduction to Plasma Physics*, Introduction to Plasma Physics (Taylor & Francis, 1995).
- [7] F. J.P., *Ideal MHD* (CUP, 2014).
- [8] C. Lechte, J. Stöber, and U. Stroth, *Physics of Plasmas* **9**, 2839 (2002).
- [9] L. L. Alves, A. Bogaerts, V. Guerra, and M. M. Turner, *Plasma Sources Science and Technology* **27**, 023002 (2018).
- [10] L. Zhong, B. Wu, and Y. Wang, *Physics of Fluids* **34**, 087116 (2022).
- [11] J. Trieschmann, L. Vialetto, and T. Gergs, *Journal of Micro/Nanopatterning, Materials, and Metrology* **22**, 041504 (2023).
- [12] J. Seo, I. Kim, and H. Nam, *Nuclear Engineering and Technology* **56**, 5396 (2024).
- [13] A. Mathews, M. Francisquez, J. W. Hughes, D. R. Hatch, B. Zhu, and B. N. Rogers, *Phys. Rev. E* **104**, 025205 (2021).
- [14] G. Cybenko, *Mathematics of Control, Signals and Systems* **2**, 303 (1989).
- [15] K. Hornik, M. Stinchcombe, and H. White, *Neural Networks* **2**, 359 (1989).
- [16] D. Ray, O. Pinti, and A. A. Oberai, “Deep learning and computational physics (lecture notes),” (2023).
- [17] X. Glorot and Y. Bengio (2010) pp. 249–256.
- [18] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” (2017).
- [19] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Köpf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, “Pytorch: an imperative style, high-performance deep learning library,” in *Proceedings of the 33rd International Conference on Neural Information Processing Systems* (2019) pp. 8024–8035.
- [20] C. Giroud, A. Meakins, M. Carr, A. Baciero, and C. Bertrand, “Cherab Spectroscopy Modelling Framework,” (2018).
- [21] C. M. Roach, M. Walters, R. V. Budny, F. Imbeaux, T. W. Fredian, M. Greenwald, J. A. Stillerman, D. A. Alexander, J. Carlsson, J. B. O. Caughman, *et al.*, *Nuclear Fusion* **48**, 125001 (2008).
- [22] J. A. Stillerman, T. W. Fredian, K. A. Klare, and G. Manduchi, *Review of Scientific Instruments* **68**, 939 (1997).